

## Hiyerarşik Olmayan Kümelendirme

### k-Ortalamalar Yöntemi

Başlangıçta belirlenen belli sayıda ki küme içi toplam ortalamayı minimize etmek amaçtır.  $N$  boyutlu uzayda  $N$  adet örnekle kümelerin verildiğini varsayalım. Bu uzay  $\{C_1, C_2, \dots, C_k\}$  biçiminde  $k$  adet kümeye ayrılır. 0 zaman

$\sum n_k = N$   $k=1, 2, \dots, k$  o.ü  $C_k$  kümesinin ortalamı vektörü  $M_k$ ;

$$M_k = \frac{1}{n_k} \sum_{i=1}^{n_k} x_{ik}$$

$x_k$   $C_k$  kümesine ait olan  $i$  örnektir.  $C_k$  kümesi için hata-kare her bir  $C_k$  örneği ile onun merkezi (centroid) arasındaki öklid uzaklıkları toplamıdır. Bu hataya küme içi değişim adı da verilir. Küme içi değişimler

$$Q_{i0}^2 = \sum_{i=1}^{n_k} (x_{ik} - M_k)^2$$

$k$  kümesini içeren bütün kümeler uzayı için hata-kare küme içindeki değişimlerin toplamıdır. O halde söz konusu hata-kare değeri şu şekilde hesaplanır

$$E_k^2 = \sum_{k=1}^K Q_k^2$$

Kore-hota kümelere yönteminin amacı verilen  $K$  değeri için  $E_k^2$  değerini minimize eden  $K$  kümelerini bulmaktır.

O halde  $K$ -ort. algoritmasında  $E_k^2$  değerinin bir önceki iterasyona göre azalması beklenir.

### Algoritma

$K$ -ortalama algoritmasına başlamadan önce  $K$  küme sayısını belirlemesi gerekir.  $K$  belirlendikten sonra her bir kümeye gözlem değerleri atanır böylece  $C_1, C_2, \dots, C_K$  kümeleri belirlenmiş olur.

a) Her bir ~~küme~~ kümenin merkezi belirlenir. Bu merkezler  ~~$M_1, M_2, \dots, M_K$~~   $M_1, M_2, \dots, M_K$  biçiminde

b)  $a_1, a_2, \dots, a_k$  kümeler içi değişimler hesaplanır. Bu değişimleri toplamı olan  $E_k^2$  değeri bulunur

c)  $M_k$  merkez değerleri ile gözlem değerleri arasındaki uzaklıklar hesaplanır. Bir gözlem değeri hangi merkeze yakın ise o merkez ile ilgili küme içine dahil edilir

d) Yukarıda ki b ve c adımları, kümelere her hangi bir değişim olmayıncaya kadar devam ettirilir.

## Uygulama

$x_i$	Değişken 1	Değişken 2
$x_1$	4	2
$x_2$	6	4
$x_3$	5	1
$x_4$	10	6
$x_5$	11	8

$k$ -ort ile  $k=2$  için veriler.  
kümeleyin

$k=2$  için tesadüfî olarak iki kümeye bölüyoruz

$$C_1 = \{x_1, x_2, x_4\}$$

$$C_2 = \{x_3, x_5\}$$

Görlem	Değişken 1	Değişken 2	Küme üyeliği
$x_1$	4	2	$C_1$
$x_2$	6	4	$C_1$
$x_3$	5	1	$C_2$
$x_4$	10	6	$C_1$
$x_5$	11	8	$C_2$

Adım 1

Yukarıda belirtilen kümenin merkezleri

$$M_1 = \left\{ \frac{4+6+10}{3}, \frac{2+4+6}{3} \right\} = M_1 = \{6.67, 4\}$$

$$M_2 = \left\{ \frac{5+11}{2}, \frac{1+8}{2} \right\} = \{8, 4.5\}$$

Küme içi değerler

$$a_1^2 = [(4-6.67)^2 + (2-4)^2] + [(6-6.67)^2 + (4-4)^2] + [(10-6.67)^2 + (6-4)^2]$$

$$a_1^2 = 26.67$$

$$a_2^2 = [(5-8)^2 + (1-4.5)^2] + [(11-8)^2 + (8-4.5)^2]$$

$$a_2^2 = 42.5$$

$$E^2 = a_1^2 + a_2^2 = 26.67 + 42.5 \quad \boxed{E^2 = 69.17}$$



$M_1$  ve  $M_2$  merkezlerinden uzaklıkların minimum olması için Öklid uzaklık formülü ile mesafeler hesaplanır.

$$(M_1, x_1) \text{ ikilisi için } M_1 = \{6.67, 4\} \quad x_1 = \{4, 2\}$$

$$d(M_1, x_1) = \sqrt{(6.67-4)^2 + (4-2)^2} = 3.33$$

$M_2 = \{8, 4.5\}$  ve  $x_1 = \{4, 2\}$  olduğuna göre  $(M_2, x_1)$  uzaklığı,

$$d(M_2, x_1) = \sqrt{(8-4)^2 + (4.5-2)^2} = 4.72$$

$$d(M_1, x_1) < d(M_2, x_1)$$

Bu durumda  $M_1$  merkezinin  $x_1$  gözlem değerine daha yakın olduğu anlaşılır. O halde  $x_1 \in C_1$  kabul edilir. Benzer şekilde

Gözlemler	$M_1$ den uzaklık	$M_2$ den uzaklık	Küme üyeliği
$x_1$	$d(M_1, x_1) = 3.33$	$d(M_2, x_1) = 4.72$	$C_1$
$x_2$	$d(M_1, x_2) = 0.67$	$d(M_2, x_2) = 2.06$	$C_1$
$x_3$	$d(M_1, x_3) = 3.43$	$d(M_2, x_3) = 4.61$	$C_1$
$x_4$	$d(M_1, x_4) = 3.89$	$d(M_2, x_4) = 2.5$	$C_2$
$x_5$	$d(M_1, x_5) = 5.9$	$d(M_2, x_5) = 4.61$	$C_2$

Bu durumda yeni üyeliğe r.

$$C_1 = \{x_1, x_2, x_3\}$$

$$C_2 = \{x_4, x_5\}$$

Adım 2

(5)

~~Yeni~~ belirlenen yeni küme merkezleri

$$M_1 = \left\{ \frac{4+6+5}{3}, \frac{2+4+1}{3} \right\} \quad M_1 = \{5, 2.33\}$$

$$M_2 = \left\{ \frac{10+11}{2}, \frac{6+8}{2} \right\} \quad M_2 = \{10.5, 7\}$$

Küme içi değişimler şu şekilde hesaplanır.

$$a_1^2 = [(4-5)^2 + (2-2.33)^2] + [(6-5)^2 + (4-2.33)^2] + [(5-2.33)^2 + (1-2.33)^2]$$

$$a_1^2 = 9.33$$

$$a_2^2 = [(10-10.5)^2 + (6-7)^2] + [(11-10.5)^2 + (8-7)^2]$$

$$a_2^2 = 2.50$$

Toplam kare-hata

$$E^1 = a_1^2 + a_2^2 = 9.33 + 2.5$$

$$E^2 = 11.83$$

Bir önceki  $E^2 = 69.17$  önceki  $E^2 = 11.83$  yeni toplam kare hata daha küçüktür.

$M_1$  ve  $M_2$  merkezlerinden gözlemlerin uzaklıkları hesaplanır.  $(d(M_1, X_i) < d(M_2, X_i))$  kriteri ile sınıflamalar yapılır.

Gözlemler	$M_1$ den uzaklık	$d(M_2, X_i)$	Küme üyeliği
$X_1$	$d(M_1, X_1) = 1.05$	8.20	$C_1$
$X_2$	$d(M_1, X_2) = 1.94$	5.41	$C_1$
$X_3$	$d(M_1, X_3) = 1.33$	8.14	$C_1$
$X_4$	$d(M_1, X_4) = 6.20$	1.12	$C_2$
$X_5$	$d(M_1, X_5) = 8.25$	1.12	$C_2$

Küme üyeliği  $C_1 = \{X_1, X_2, X_3\}$

$C_2 = \{X_4, X_5\}$

Değişme olmadığı için iterasyona son verilir.

